



研究思路头脑风暴 选题

</> 代码

序号	要点	要点问题	对应论文 章节	回答 及说 明	备注
1	选题	要解决的问题是什么？问题是否明确、具体、可验证？	引言 / 第1章		
2	研究意义	假设问题能解决，会带来什么理论或实践上的好处？	引言		
3	研究现状	既然有这么大好处，以前有哪些研究尝试解决该问题？	相关工作		注意引用最新、权威文献
4	研究贡献	本研究相较已有工作，贡献或特色（不同且进步之处）在哪里？	引言 / 总结		
5	研究方法	从理论和技术上，本研究采用了哪些方法支撑研究贡献？	方法章节		
6	研究结果	有哪些实验或分析结果印证研究贡献？	实验章节		
7	工作	工作量是否充足？研究过程是否体现系统性与完整性？	全文		非必填项

序号	要点	对应论文章节	回答及说明	备注
	态度			

选题:面向客户的人机混合智能体调度系统

整体思路：论文提出了一种面向客户的“人机混合智能体调度系统”，其完整闭环是：首先通过意图分类将用户问题分配给对应的AI智能体，系统无法处理的异常问题（OOS）将被系统进一步判断进行人（客服）机（通用LLM）分配进行问题回答。创新点3是整体系统

- 由于客服领域的特殊性，相关工作适合用智能体替代
 - 特殊性是啥待补充
 - 人存在什么问题
 - 智能体有什么好处
- 但是直接使用用不了
 - 在垂直行业（如金融股票等）的实际应用中。
 - 垂直领域是什么？
 - 用户交流往往不充分，存在模糊、残缺或仅包含部分关键词
 - （例如用户仅输入“计算机应用”，其实际意图是“选出计算机应用相关的股票”）
 - 为什么会这样？（扩展）
 - 约定俗成
 - 高效交流

整体思路 提出一种面向客户服务场景的人机混合智能体调度系统，完整闭环包括：

意图分类：将用户问题精准分配给对应领域的AI智能体；

OOS检测与分配：对无法分类的异常问题（OOS，Out-of-Scope），根据问题复杂度和风险等级动态分配给人工客服或通用大语言模型（LLM）处理。

系统整合：将前两步封装为可部署的混合调度框架，实现效率与质量的平衡。

创新点1

创新点1思路：

- 当前问题：
 - 研究现状部分残缺：仅提及“IntentGPT”，未展开其具体方法、与其他方法的对比，以及为何它是现有研究的代表，需补充完整。

- 研究贡献中“有什么作用”空白：必须明确该创新点带来的实际收益（如分类准确率提升、延迟降低等），否则贡献不清晰。
- 研究方法中未解释200字限制的原因：需说明该限制的来源（如模型输入长度、工业界实际约束）及其对信息压缩的必要性。
- 研究结果（实验）完全缺失：必须补充实验设计（数据集、对比基线、评价指标）和预期结果，否则无法验证创新点的有效性。
- 逻辑断层：未清晰阐述“补全context”与结构化描述（C/B/R）之间的关联，需说明两者如何结合形成完整的意图分类优化方案。

• 意图分类

- 研究意义（图1.1）
 - 当前大多都是用多智能体架构处理专业领域信息问答
 - 大模型很强
 - 但依靠大语言模型统一处理专业问题存在局限性
 - 幻觉严重、领域知识缺乏、响应延迟高
 - 多智能体架构的好处是什么
 - 多智能体架构通过术业专攻提升问答质量，但高度依赖前置意图分类的准确性
- 研究现状
 - 当前研究主要围绕几个方向
 - IntentGPT
 - 现有方法缺点
 - 缺乏垂直领域上下文认知：通用模型无法准确解析高度凝练的行业术语与非标准化表达（如“语言省略”）
 - 补全context又不合适，因为知识无穷无尽
 - 智能体描述生成缺乏针对性：依赖随机采样的 **Few-shot** 或纯人工盲写，导致分类边界模糊
- 研究贡献（创新点）
 - 注意到这些问题，我们进行了改进
 - 整体的输入输出
 -

- 关键点：更好的意图分类（图1.2）
 - 在多智能体系统中保证在严格字数限制（如200字以内）下，生成更准确的智能体描述（意图类别描述），以提高意图分类的准确率。
 - 为什么要严格控制字数/为什么是200字？
 - 主要思路
 - 意图分类的本质是划定决策边界，而非穷举所有可能性
 - 分类错误主要发生在边界地带（两个相似意图的模糊区域）
 - 优化的核心是：让描述既说清“是什么”（核心能力），更说清“不是什么”（拒绝范围）和“边界在哪”（处理边界）

▪ 有什么作用

◦ 研究方法

- 公式怎么来的（为什么是 $P=\{C, B, R\}$ ）
 - 核心是将智能体的描述从“一段话”重构为一个包含三个维度的结构化元组，以提高信息密度和分类辨析度：
- C/B/R都是怎么来的？
 - C (Core Capabilities / 核心能力)：如何定义“我能做什么”来源：主要通过对智能体内部指令（ $\backslash(P_{\text{internal}})\backslash$ ）的有损压缩获得。方法：利用大模型的“逆向摘要”能力，从长达数千字的内部代码或详细指令中，榨取最核心的功能点，并限制在极短的字数内
 - B (Boundaries / 处理边界)：如何界定“我的边界在哪”来源：基于 RAG 知识库的元数据提取。方法：如果智能体依赖外部知识库，其边界由知识库的元数据（如分类、时间范围、产品线）直接决定。通过读取这些元数据，可以硬性划定该智能体能回答的拓扑范围
 - R (Rejections / 拒绝范围)：如何明确“我不做什么”来源：基于 Bad Case（错误案例）的逆向生成。方法：针对分类失败的“边界地带”（即容易混淆的类别），通过对比法提取互斥特征。明确加入排他性指令，例如：“不处理退换货”或“不处理已付款订单”
- 怎么保证系统越用越好（系统持续迭代优化）
 - 边界对比优化 (Contrastive Optimization)：强调“与谁不同”。在描述中不仅写自己能做什么，还要针对容易混淆的邻近智能体加入排他性说明。
 - 基于数据的逆向精炼 (Data-Driven Refinement)：利用错误日志，将分类错误的案例反哺给大模型，让大模型分析为什么会分错，并据此修正描述中的歧义。
 - 信息瓶颈理论 (Information Bottleneck)：这是一个理论依据。目标是在保留对意图类别最大预测能力的同时，尽可能压缩源信号，确保在 200 字限制内保留最高价值的信息。

◦ 研究结果（实验）

- 基于领域上下文（Context）的查询重构机制
 - 垂直领域用户交互特征分析
 - 用户群体基于领域共识形成信息压缩的表达习惯
 - 行业级 Context 规则库构建
 - 提取并固化特定领域的先验规则（如金融理财中的特定缩略语解析）
 - 输入端语义补全与对齐
 - 在进入分类器前，利用规则将模糊、残缺的语义片段显式扩写为标准化意图指令
 - 消除通用大模型与垂直领域之间的信息壁垒，降低分类器推理难度
- 数据驱动的智能体特征描述与 Few-shot 优化
 - 基于错误样本（Bad Case）的闭环迭代挖掘
 - 摒弃随机生成与人工硬编码，通过分析历史误判数据的错分规律提取易混淆语义特征
 - 结合约束条件的高信噪比描述生成
 - 引入严格的输出长度约束（如100字以内），强制大模型进行高度概括
 - 提炼各子智能体的核心功能边界（Summary）
 - 结构化提示词重构
 - 将优化后的精确描述与动态筛选的高质量 Few-shot 样例融合
 - 显著提升核心大模型分类器的鲁棒性与准确率
- 面向低延迟的自适应大小模型协同路由
 - 工业级系统延迟瓶颈分析
 - 大语言模型全量串行推理导致的资源消耗与用户体验下降
 - 轻量级前置路由机制设计
 - 训练小参数量模型进行分类置信度计算与初步意图识别
 - 建立基于置信度阈值的分流策略
 - 效能提升表现